Sunum Notları: TerraMind / SmallMinesDS

Oct 21, 2026 · Asım Emre Arslan

Ana mesaj

Soru: Az etiketli veriyle maden segmentasyonunda, hazır eğitilmiş TerraMind encoder'ı mı, sıfırdan eğitilen aynı model mi daha iyi; ve görüntü döndürme (augmentation) ne kadar katkı sağlıyor?

1. **Ön eğitimli, dondurulmuş encoder kazanıyor:** N ⩾ 10'da her seed'de önde; tüm veriyle IoU 0,745'e karşı 0,673.
2. **Veri verimliliği:** Ön eğitimli encoder 10 görüntüyle, sıfırdan eğitilenin 250 görüntüyle ulaştığı seviyeye ulaşıyor (yaklaşık 0,59).
3. **Augmentation:** Ön eğitimli encoder'a her N ⩾ 3'te, her seed'de +0,02–0,04 IoU katıyor; sıfırdan eğitilende tutarlı etkisi yok.
4. **Güvenilirlik:** Ön eğitimli encoder'ın sonuçları seed'den seed'e çok az değişiyor; sıfırdan eğitilende dağılım 2–3 kat geniş (Figure 2).

Terimler

Grup	Terim	Kısa açıklama
Veri	SmallMinesDS	Gana'daki küçük ölçekli altın madenlerini haritalamak için hazırlanmış açık uydu veri seti; 2022 yılını kullandık
Veri	Sentinel-2	Avrupa Uzay Ajansı'nın optik uydusu; renk ve kızılötesi dahil 10 bant kullandık
Veri	Sentinel-1	Radar uydusu; buluttan etkilenmez, yüzey dokusu ve nemi gösterir; 2 bant (VV, VH)
Veri	128 × 128 px patch	Her görüntü 128×128 piksellik parça; 1 piksel ≈ 10 m, yani ≈ 1,3 × 1,3 km
Veri	Train / test (1.491 / 644)	Model 1.491 görüntüden öğreniyor; başarı hiç görmediği 644 görüntüde ölçülüyor
Veri	N	Bir çalıştırmada kullanılan eğitim görüntüsü sayısı: 1–1000 ve "all" = 1.491

Grup	Terim	Kısa açıklama
Veri	Maske, segmentasyon	Her pikselin “maden / değil” etiketi; modelin bunu piksel piksel tahmin etmesi segmentasyon
Model	Encoder	Görüntüden anlamlı özellikler çıkaran kısım
Model	Decoder	Özelliklerden piksel piksel maden haritası üreten kısım
Model	TerraMind v1 tiny	IBM ve ESA'nın milyonlarca uydu görüntüsüyle önceden eğittiği temel model (foundation model); en küçük sürüm, ≈ 5,9 M parametre
Model	Shallow UNet decoder	Segmentasyonda standart decoder tipi; “shallow” = az katmanlı, ≈ 1 M parametre; her koşulda aynı
Model	Pretrained, frozen	Encoder TerraMind'ın hazır ağırlıklarıyla gelir ve hiç değişmez; yalnızca decoder öğrenir
Model	Random init, trainable	Aynı encoder rastgele ağırlıklarla başlar ve decoder'la birlikte sıfırdan eğitilir
Eğitim	D4 augmentation	Her görüntüyü 8 şekilden birinde rastgele döndürmek/aynalamak (0/90/180/270°, aynalı ya da değil); test görüntülerine uygulanmaz, N'yi artırmaz
Eğitim	Epoch	Tüm eğitim görüntülerinin bir kez görülmesi; her çalıştırma 50 epoch
Eğitim	Batch, step	Görüntüler 8'erli gruplar (batch) halinde görülür; her batch'ten sonra bir güncelleme (step); N=1'de 50, tüm veride 9.350 step
Eğitim	AdamW	Ağırlıkları güncelleyen standart algoritma (optimizer)
Eğitim	Learning rate	Her adımda ağırlıkların ne kadar değişeceği
Eğitim	Cosine schedule 5e-3 → 1e-5	Öğrenme hızı 0,005'ten başlayıp kosinüs eğrisiyle 0,00001'e iner: başta hızlı öğrenme, sonda ince ayar
Eğitim	Seed	Rastgelelik numarası: hangi görüntüler, decoder başlangıcı, görüntü sırası. N ⩽ 250: 5 seed; N ⩾ 500: 3 seed
Eğitim	Run	Bir N, bir koşul, bir seed için bir eğitim; toplam 196

Grup	Terim	Kısa açıklama
Sonuç	IoU	Doğru bulunan maden pikselleri ÷ (gerçek ∪ tahmin edilen maden pikselleri); 0 = hiç örtüşme yok, 1 = tam örtüşme. Hem kaçırılan madeni hem yanlış alarmı cezalandırır
Sonuç	Mine-class IoU	IoU yalnızca maden sınıfı için; pikselin %92'si arka plan olduğundan arka plan dahil edilmez
Sonuç	Mean ± std	Seed'ler üzerinden ortalama ve standart sapma; std küçükse sonuç kararlı
Sonuç	Seed-to-seed spread / variance	Aynı ayarlarla sadece seed değişince sonucun ne kadar oynadığı (Figure 2)
Sonuç	Paired gain	Aynı seed ve görüntülerle: augmentation'lı IoU − augmentation'sız IoU; sadece augmentation'ın etkisi (Table 2)
Sonuç	Seeds improved (5/5, 2/5)	Kaç seed'de augmentation IoU'yu artırdı; 5/5 tutarlı, 2/5 şans düzeyi
Sonuç	Log scale	Grafiklerde x ekseni logaritmik; 1–10–100–1000 arası eşit aralıklı

Olası sorular ve kısa cevaplar

- **Neden küçük N'ler?** Etiketli veri pahalı; az etiketle ne kadar iyi sonuç alındığını (veri verimliliği) ölçmek istedik.
- **IoU 0,745 iyi mi?** 10 m çözünürlükte küçük madenleri bulmak zor; segmentasyonda 0,7 üstü iyi sayılır. Asıl konu koşullar arası fark.
- **Neden IoU, precision/recall değil?** IoU tek sayıda hem kaçırılan madeni hem yanlış alarmı cezalandırıyor; segmentasyonda standart. Precision/recall/F1 repoda duruyor ve aynı sıralamayı veriyor.
- **Neden N ≥ 500'de 3 seed?** O çalıştırmalar çok uzun (9.350 adıma kadar) ve sonuçlar zaten çok az oynuyor (std çoğunlukla ≤ 0,009).
- **Ön eğitimli encoder'ı da eğitseydiniz?** Bu ayrı bir koşul (fine-tuning) ve bu deneyde yok. Bizim karşılaştırmada başlangıç ve eğitilebilirlik birlikte değişiyor.
- **Augmentation neden sıfırdan eğitilende işe yaramadı?** Dondurulmuş encoder'da sadece küçük decoder öğreniyor ve augmentation onu düzenli tutuyor; eğitilebilir encoder bu ek çeşitliliği 50 epoch'ta tutarlı bir kazanca çeviremiyor.

- **Küçük N'de görüntüler nasıl seçildi?** Her seed'de ilk 10 görüntü, maden oranı %25–75 olan 140 görüntüden rastgele seçildi (eğitim görüntülerinin %34'ünde hiç maden yok); kalanlar rastgele. Dört koşul aynı görüntüleri kullanıyor.
- **Neden büyük N'de daha çok adım var?** Epoch sayısı sabit (50); daha çok görüntü, epoch başına daha çok batch demek. Aynı N'de dört koşul aynı adım sayısını alıyor, karşılaştırma adil.
- **Sonuçlar tekrar üretilebilir mi?** Evet. Kod, veri indirme scripti ve 196 çalıştırmanın tüm sonuçları GitHub'da; aynı makinede bit bit aynı sonuç çıkıyor.
- **Bir çalıştırma ne kadar sürüyor?** RTX 3080 Laptop GPU'da birkaç saniyeden (N=1) yaklaşık 10 dakikaya (tüm veri) kadar; toplam yaklaşık 5 saat.